

Ham Veriden Gelişmiş Tahmin Modeline: Bisiklet Paylaşım Talebi Analiz Rehberi

Bu rehber, bir veri bilimcisinin ham veriyi alıp, karmaşık makine öğrenmesi algoritmalarıyla nasıl yüksek doğruluklu bir tahmin modeline dönüştürdüğünü adım adım açıklamaktadır. Washington D.C. bisiklet paylaşım sisteminden alınan veriler üzerinden, bir modelin sadece "kod yazmak" değil, aynı zamanda fiziksel dünyayı ve istatistiksel prensipleri anlamak olduğu gösterilecektir.

1. Veri Setinin Fiziksel Dünyasını Anlama

Bir tahmin modeline başlamadan önce, değişkenlerin fiziksel dünyada neyi temsil ettiğini ve insan davranışlarını nasıl etkilediğini anlamak gerekir. Bisiklet talebi rastgele bir sayı değildir; takvimin, hava durumunun ve kullanıcı tipinin bir sonucudur. | Grup | Değişkenler | Analitik Önem (Neden Bakıyoruz?) | Davranışsal Hipotez || ----- | ----- | ----- || **Takvimsel** | season, holiday, workingday, hour | Talebin döngüsel doğasını (işe gidiş saatleri, tatiller) belirler. | workingday, sabah ve akşam işe gidiş-dönüş "peak" saatlerini tetikler. || **Meteorolojik** | weather, temp, atemp, humidity, windspeed | Kullanıcının açık havada bisiklet sürme isteğini etkileyen fiziksel kısıtlardır. | Sıcaklık belli bir eşiğe kadar talebi artırır, ancak aşırı sıcaklık (extreme heat) sürüşü caydırır. || **Kullanıcı Türü** | casual, registered | Farklı kullanıcı gruplarının davranış rejimlerini anlamamızı sağlar. | **Registered** kullanıcılar iş odaklı ve hava durumuna dirençli; **Casual** kullanıcılar eğlence odaklı ve hava hassasiyeti yüksektir. |

Geçiş Cümlesi: Veri setinin ham halindeki değişkenleri tanıdıktan sonra, bu verilerdeki fiziksel tutarsızlıkları nasıl gidereceğimizi inceleyelim.

2. Veri Temizleme ve Meteorolojik Anomalilerin Kalibrasyonu

Sensörlerden gelen ham veriler her zaman gerçeği yansıtmaz. Fiziksel hataları düzeltmek, modelin "karar ağaçlarının" daha kararlı bölünmeler yapmasını sağlar.

- **Rüzgar Hızı (Windspeed) Sensör Eşiği:** Verideki 0.0 değerleri, genellikle rüzgarın esmediğini değil, sensörün belirli bir hızın altını ölçemediğini (threshold) gösterir. Bu "sahte sıfırları" doğrudan kullanmak gürültü yaratır. **Uzman çözümü:** Bu değerleri kayıp veri kabul edip, çevre saatlerdeki verileri kullanarak **k-NN (k-En Yakın Komşu)** veya yerel regresyon ile doldurmaktır.
- **Hissedilen Sıcaklık (Atemp) Kalibrasyonu:** Hissedilen sıcaklık verisindeki sensör kaymalarını gidermek için fiziksel sıcaklık (temp) ve nem (humidity) üzerinden doğrusal regresyon tabanlı bir kalibrasyon yapılır:
$$\text{atemp}_{\text{corrected}} = \beta_0 + \beta_1 \cdot \text{temp} + \beta_2 \cdot \text{humidity}$$
Geçiş Cümlesi: Temizlenmiş verilerle artık modelin daha iyi anlamlandırabileceği yeni özellikler üretmeye hazırız.

3. Özellik Mühendisliği: Zamanın Döngüsellliği ve Etkileşimler

Ham veriyi modele olduğu gibi vermek yerine, ona "dünyanın nasıl işlediğini" anlatan matematiksel sinyaller eklemeliyiz.

Zamanın Döngüsellığı

Saat verisi (0-23) lineer verildiğinde model 23 ile 0'ı birbirinden uzak sanır. Oysa bu saatler birbirine komşudur. Bu sürekliliği **Sinüs/Kosinüs dönüşümü** veya **SplineTransformer** ile sağlarız:
$$\sin(\text{hour}) = \sin\left(\frac{2\pi}{24} \cdot \text{hour}\right), \quad \cos(\text{hour}) = \cos\left(\frac{2\pi}{24} \cdot \text{hour}\right)$$

Yoğun Saat (Rush Hour) Etkileşimi

İşe gidiş-dönüş saatlerindeki keskin talebi yakalamak için workingday ve kritik saatleri birleştiririz:
$$\text{is_rush_hour} = \mathbb{I}(\text{workingday} = 1) \times \mathbb{I}(\text{hour} \in \{7, 8, 9, 17, 18, 19\})$$
 İpucu Kutusu: Konfor Endeksi (Humidex) İnsanlar sıcaklığı sadece derece olarak değil, nemle birleşimiyle hissederler. Aşağıdaki formül, nem ve sıcaklığın kullanıcı üzerindeki birleşik etkisini tekil değişkenlerden daha iyi açıklar:
$$\text{comfort_index} = \text{temp} + \frac{5}{9} \left(\left(6.11 \cdot \exp\left(\frac{17.27 \cdot \text{temp}}{237.7 + \text{temp}}\right) \cdot \frac{\text{humidity}}{100} \right) - 10 \right)$$
 Geçiş Cümlesi: Özellikleri zenginleştirdik, ancak modelimizin başarısını ölçmek için gerçekçi bir "sınav" ortamı kurmamız gerekiyor.

4. Doğrulama Stratejisi: Neden Rastgele Değil, Zamansal Blok Doğrulama?

Zaman serisi verilerinde rastgele bölme (i.i.d.) yapmak, modelin "gelecekteki bilgi sızdırmasına" (leakage) neden olur. | Strateji | Yöntem | Risk / Durum || ----- | ----- | ----- || **Standart K-Fold** | Veriyi rastgele karıştırır. | **Risk:** $t-1$ ve $t+1$ arasındaki ilişkiyi kullanarak hile yapar. Gerçek dünyada modelin performansını abartır. || **Zamansal Blok** | Ayın ilk 19 gününü eğitim, 20-31. günlerini test olarak ayırır. | **Avantaj:** Modelin hiç görmediği bir "gelecek bloğunu" tahmin etme yeteneğini ölçer. |

⚠ Kritik Uyarı: UCI Veri Sızıntısı (Public Leak)

Kaggle'daki test verileri (ayın 20-31. günleri) aslında internetteki UCI veri depolarında halka açık haldedir. Bu verileri indirip modele göstermek size **0.0 RMSLE** skoru (kusursuz tahmin) kazandırır da, bu bir veri bilimi başarısı değil, metodolojik bir hatadır. Gerçek bir model, dışarıdaki cevap anahtarını görmeden tahmin yapabilmelidir. **Geçiş Cümlesi:** Doğru bir ölçüm sistemi kurduktan sonra, bu karmaşık örüntüleri öğrenmek için en uygun model ailesine geçebiliriz.

5. Modelleme Stratejisi: Ağaç Tabanlı Modeller ve İkili Hedef Yaklaşımı

Doğrusal olmayan ilişkilerin (sıcaklık-nem etkileşimi gibi) yoğun olduğu bu veri setinde "Gradient Boosting" ailesi rakipsizdir. | Algoritma | Mimari Avantaj | Kategorik Veri İşleme || ----- | ----- | ----- || **XGBoost** | Seviye bazlı (level-wise) büyüme. L1/L2 regülerizasyonu güçlüdür. | Ön işleme (Encoding) gerektirir. || **LightGBM** | Yaprak bazlı (leaf-wise) büyüme. Çok hızlı ve düşük bellek kullanımı. | Kategori bazlı histogram gruplama (Fisher yöntemi). || **CatBoost** | Simetrik ağaç yapısı. Küçük veri setlerinde bile çok kararlıdır. | "Ordered Boosting" ile sızıntıyı önler ve kategorikleri mükemmel işler. |

İkili Hedef Yaklaşımı (Casual vs. Registered)

Toplam talebi (count) tek bir modelle tahmin etmek yerine, casual ve registered kullanıcıları ayrı modellerle tahmin edip toplamak doğruluğu artırır. Çünkü kayıtlı kullanıcılar işe gitmek için "yağmura dirençli" bir profil çizerken, anlık kullanıcılar sadece güzel havalarda ortaya

çıkar. Farklı davranış rejimlerini ayrı modellerle yakalamak stratejik bir üstünlüktür. **Geçiş Cümlesi:** Modelimizi seçtik, ancak hedef değişkenimizin matematiksel dağılımı modelin öğrenmesini zorlaştırabilir.

6. Hedef Dönüşümü ve Retransformasyon Yanlılığının Giderilmesi

Bisiklet sayıları "çarpık" (skewed) bir dağılım sergiler. Modelin uç değerlerden (outliers) sapmasını engellemek için log1p (logaritma) dönüşümü kullanılır. Ancak, log-uzayında yapılan tahminleri orijinal sayıya çevirirken bir tuzakla karşılaşırız.

Jensen Eşitsizliği ve Düzeltme

Logaritma içbükey bir fonksiyon olduğu için, log-tahminlerini doğrudan geri çevirdiğimizde (expm1), sonuçlar sistemli olarak gerçek değerden **düşük** çıkar. Bu negatif yanlılığı düzeltmek için **Duan's Smearing Estimator** kullanılır. Önce modelin hatalarının (e_i) ortalamasından bir düzeltme faktörü (θ) hesaplanır: $\theta = \frac{1}{N} \sum_{i=1}^N \exp(e_i)$ Ardından final tahmin şu şekilde düzeltilir:

$\hat{y}_{\text{corrected}} = \theta \cdot \exp(\hat{y}_{\log}) - 1$ **Geçiş Cümlesi:** Modeli eğitmek yeterli değildir; nerede hata yaptığımızı anlamak için artıkların derinliklerine inmeliyiz.

7. Hata Analizi: Model Nerede Çuvallıyor?

Modelin başarısını sadece tek bir skorla değil, hataların dağılımıyla ölçeriz.

- **Eş Varyanslılık (Homoscedasticity):** Modelin hataları, tahmin edilen değer boyunca rastgele dağılmalıdır. Eğer talep arttıkça hata payı da büyüyorsa, modelin belirsizliği taleple birlikte artıyor demektir.
- **Zirve Saatleri Hatası (Peak Underprediction):** Logaritmik dönüşüm, yüksek değerlerdeki hataları "sıkıştırır". Bu da modelin en yoğun saatleri (1000 yerine 900 gibi) sistematik olarak düşük tahmin etmesine yol açar.
- **Çözüm - Ağırlıklı Eğitim (Sample Weighting):** Modelin eğitiminde yüksek talep saatlerine daha fazla "ağırlık" (weight) vererek veya "Asymmetric MSE" gibi özel kayıp fonksiyonları kullanarak bu yanlılık giderilebilir.

Öğrenci İçin Kritik Çıkarımlar

1. **Fiziksel Mantık:** atemp kalibrasyonu ve rüzgar hızı düzeltmesi gibi adımlar, modelin "çöp veri" ile beslenmesini önler.
2. **Validasyon Kutsaldır:** Zaman serisinde rastgele split yapmaktan ve UCI sızıntısından kaçınmak, modelin gerçek dünyada çalışmasını sağlar.
3. **Matematiksel Düzeltme:** Logaritmik dönüşüm sonrası Duan's Smearing gibi bir düzeltme yapmamak, modelinizin her zaman eksik tahmin yapmasına neden olur.