

Tahmin Modellerinde Doğruluğu Artıran İleri Metodolojik Yaklaşımlar: Teknik Metodoloji Raporu

1. Giriş ve Stratejik Çerçeve

Modern akıllı ulaşım ekosistemlerinde, Washington D.C. Capital Bikeshare (2011–2012) gibi mikro-mobilité ağı için geliştirilen uzay-zamansal (spatiotemporal) talep tahmin modelleri, operasyonel verimliliğin sınır merkezidir. Talebin saatlik bazda hassas bir şekilde öngörülmesi, yalnızca bir regresyon başarısı değil; filo yeniden dengeleme (rebalancing), istasyon kapasite yönetimi ve lojistik maliyetlerin minimize edilmesi süreçlerinde doğrudan bir maliyet tasarrufu mekanizmasıdır. Tahmin doğruluğundaki %1'lik bir iyileşme, yoğun saatlerdeki arz darboğazlarını önleyerek kullanıcı memnuniyetini ve sistem sürdürülebilirliğini artırır. Bu rapor, ham verinin fiziksel gerçeklikle uyumlu hale getirilmesinden başlayarak, gelişmiş gradyan artırma ensemeleri ve matematiksel bias düzeltme yöntemlerine kadar uzanan, yüksek kapasiteli bir mimari yol haritası sunmaktadır. Veri kalitesinin ve metodolojik titizliğin model başarısındaki rolü, "çöp içeri, çöp dışarı" (garbage in, garbage out) prensibinin ötesinde, yapısal bir mühendislik gerekliliğidir.

2. Veri Anlama ve Fiziksel Hipotezlerin Kalibrasyonu

Ham çevresel telemetri verileri, sensörlerin fiziksel sınırları ve kalibrasyon hataları nedeniyle sıklıkla gürültü barındırır. Washington D.C. veri setinde gözlemlenen anomalilerin dekonstrüksiyonu, modelin fiziksel dünyayı doğru anlaması için elzemdir.

Meteorolojik Anomalilerin Dekonstrüksiyonu

- **Rüzgar Hızı (Windspeed) Eşik Hataları:** Veri setindeki yoğun \$0.0\$ rüzgar hızı değerleri, genellikle gerçek bir durgun havayı değil, sensörlerin düşük hızları algılayamaması (anemometre başlangıç eşiği) sonucunda oluşan "kayıp verileri" temsil eder. Bu durumun doğrudan modele verilmesi, gradyanlarda yapay bir gürültü yaratır.
- **Hissedilen Sıcaklık (Atemp) Tutarsızlıkları:** İnsan ısı algısını temsil eden atemp, nem ve rüzgarın bir fonksiyonudur. Sensör kaymaları nedeniyle oluşan tutarsızlıkları gidermek için atemp değişkeni, fiziksel sıcaklık (temp) ve bağıl nem (humidity) üzerinden yeniden inşa edilmelidir.

Teknik Kalibrasyon Prosedürü

Anomali giderme sürecinde şu bilimsel adımlar izlenmelidir:

1. **k-En Yakın Komşu (k-NN) veya Regresyon İmpütasyonu:** Rüzgar hızı \$0.0\$ olan kayıtlar maskelenmeli ve zamansal olarak yakın komşuluklar kullanılarak doldurulmalıdır.
2. **Termodinamik Rekonstrüksiyon:** atemp değerleri, temiz kayıtlar üzerinden eğitilen aşağıdaki doğrusal model ile kalibre edilmelidir:
$$\text{atemp}_{\text{corrected}} = \beta_0 + \beta_1 \cdot \text{temp} + \beta_2 \cdot \text{humidity}$$
 Bu düzeltmeler, ağaç tabanlı modellerin (GBDT) fiziksel olarak anlamlı ayrışma (split) noktaları bulmasını sağlayarak özellik temsil gücünü artırır.

3. İleri Düzey Özellik Mühendisliği ve Temsil Stratejileri

Ham girdilerin, makine öğrenmesi modellerinin kapasitesine uygun doğrusal olmayan sinyallere dönüştürülmesi, tahmin hatasını minimize etmenin en etkili yoludur.

Periyodik Zaman Özellikleri ve Spline Dönüşümü

Zamanın dairesel doğasını (saat 23'ten sonra 0 gelmesi) tamsayı kodlamasıyla temsil etmek matematiksel bir süreksizlik yaratır.

- **Sinüs-Kosinüs Dönüşümü:** Zaman dairesel koordinatlara taşınmalıdır:
$$\sin(\text{hour}) = \sin\left(\frac{2\pi}{24} \cdot \text{hour}\right), \quad \cos(\text{hour}) = \cos\left(\frac{2\pi}{24} \cdot \text{hour}\right)$$
- **Periodic Spline Transformasyonu:** Doğrusal modeller (Ridge/Lasso) için dairesel sürekliliği sağlayan daha esnek bir temsil sunar. Ağaç tabanlı modeller ordinal değerlerle çalışabilse de, periyodik splinelar modelin zamansal sınırları daha pürüzsüz öğrenmesini sağlar.

Etkileşim ve Alan İndeksleri

- **Konfor İndeksi (Humidex):** Isı yorgunluğuna bağlı talep düşüşlerini yakalamak için formüle edilir:
$$\text{comfort_index} = \text{temp} + \frac{5}{9} \left(\left(6.11 \cdot \exp\left(\frac{17.27 \cdot \text{temp}}{237.7 + \text{temp}}\right) \cdot \frac{\text{humidity}}{100} \right) - 10 \right)$$
- **Yoğun Saat (Rush Hour) Göstergesi:** İş günleri ile hafta sonu rejimlerini ayıran kritik bir değişkendir:
$$\text{is_rush_hour} = \mathbb{I}(\text{workingday} = 1) \times \mathbb{I}(\text{hour} \in \{7, 8, 9, 17, 18, 19\})$$
- **Gün Tipi Kategorizasyonu:** Boyut indirgemek ve rejimleri netleştirmek adına takvim verileri; Hafta içi (Weekday), Hafta sonu (Weekend) ve Tatil (Holiday) olarak üçlü bir kategorik yapıda gruplandırılmalıdır.

4. Zaman Serisi Doğrulama ve Hedef Sızıntısı (Target Leakage) Yönetimi

Tahmin modellerinin en büyük yapısal riski "Gelecekte Bilgi Sızması"dır. Kaggle Bike Sharing veri setinde eğitim (1-19. günler) ve test (20-31. günler) ayrımı, sızıntı yönetimi için özel bir dikkat gerektirir.

Yapısal Tuzak: UCI Kamu Veri Seti Sızıntısı

Kaggle'daki test günlerinin gerçek değerleri UCI kamu veri setinde mevcuttur. Bu verilerin eğitim veya doğrulama aşamasında kullanılması, \$0.0\$ RMSLE skoru gibi yapay sonuçlar üretir ve modelin gerçek dünya genelleme yeteneğini yok eder. Bir mimar olarak bu sızıntı "yapısal bir tuzak" olarak tanımlanmalı ve kesinlikle dışlanmalıdır.

Gecikme (Lag) Özellikleri ve Validasyon

Gecikme özellikleri kurulurken iki ana paradigma izlenebilir:

1. **Özyinelemeli (Recursive) Paradigma:** Model kendi tahmini $\hat{Y}_{t-1}$ 'i bir sonraki adımın girdisi yapar.
2. **Yapısal Boşluk (Structural Gap) Paradigması:** Test periyodunun tamamını kapsayan (örn. 12 gün öncesi) güvenli gecikmeler kullanılır. **Zaman-Farkındalıklı Doğrulama:** Rastgele K-fold geçersizdir. TimeSeriesSplit kullanılırken, eğitim ve doğrulama blokları arasında sızıntıyı önlemek için en az gap=48 (48 saatlik kronolojik tampon) uygulanmalıdır.

5. Çoklu Model Mimarileri ve Gradyan Artırma Ensemli

Toplam talebi (count) tek bir değişken olarak tahmin etmek, 'Casual' ve 'Registered' kullanıcıların taban tabana zıt davranışlarını (eğlence vs. ulaşım) maskeler. Hassasiyeti artırmak için bu iki grup ayrı modellenmeli ve sonuçlar orijinal ölçekte toplanmalıdır.

Algoritma ve Performans Karşılaştırması

Aşağıdaki tablo, spatiotemporal ulaşım verilerindeki benchmark sonuçlarını özetlemektedir:

Model Ailesi	Algoritma / Mimari	MAE	RMSE	P80 Coverage (%)	Yapısal Özellik	
-----	-----	-----	-----	-----		
-----	-----	-----	-----	-----		
Level-wise, L1/L2 Regularization		GBDT Ensemble	XGBoost	51.79	89.13	59.14
Symmetric Trees		Deep Sequential	N-BEATS	51.33	75.88	44.84
İleri beslemeli blok yapısı		Deep Transformer	TFT	55.90	90.87	72.14
Belirsizlik Tahmini & P80 Kapsamı						

Analitik Sentez: Noktasal tahmin doğruluğunda XGBoost ve N-BEATS liderlik ederken, operasyonel planlama ve risk yönetimi (belirsizlik tahmini) için **Temporal Fusion Transformer (TFT)** sunduğu yüksek P80 kapsama oranıyla tercih edilmelidir.

6. Hedef Dönüşümü ve Jensen Eşitsizliği Kaynaklı Sistemik Yanlılık

RMSLE optimizasyonu için sıklıkla kullanılan $\log(y+1)$ dönüşümü, retransformasyon aşamasında istatistiksel bir sapmaya yol açar.

Jensen Eşitsizliği ve Yanlılık

Konkav fonksiyonlarda (logaritma gibi), fonksiyonun beklenen değeri, beklenen değer fonksiyonundan küçüktür ($E[\log(Y)] \leq \log(E[Y])$). Bu matematiksel gerçek, log-alanında yapılan tarafsız tahminlerin orijinal ölçeğe ($\exp$) döndürüldüğünde talebi sistemik olarak **eksik tahmin etmesine (underestimation)** neden olur.

Genelleştirilmiş Kaydırma Parametresi (Shift Parameter)

Varyans stabilizasyonu ve gradyanların stabilize edilmesi için $y_{\text{shift}} = \log(y + c)$ dönüşümü önerilir. Burada $c=100$ gibi bir sabit kullanılması, modelin sıfıra yakın değerlerdeki aşırı hassasiyetini azaltarak uçuculuğu (volatility) bastırır.

7. Matematiksel Bias Düzeltme Metotları: Duan'ın Yayma Tahminci

Sistemik eksik tahmini gidermek için geri dönüşüm (back-transformation) sırasında düzeltme faktörü uygulanmalıdır.

- Duan'ın Non-Parametrik Yayma Tahminci (θ):** Rezidülerin ($\exp(e_i)$) ortalaması üzerinden hesaplanır: $\hat{y}_{\text{corrected}} = \theta \cdot \exp(\hat{y}_{\log}) - c$. Bu düzeltme genellikle tahminleri %5-20 oranında yukarı çekerek gerçek ortalamaya yaklaştırır.
- Parametrik Düzeltme:** Rezidülerin normal dağıldığı varsayılırsa, varyansın yarısı ($\sigma^2/2$) tahminlere eklenir.
- GLM Alternatifi:** Log-link fonksiyonlu Poisson veya Gamma GLM'ler, beklentiyi doğrudan orijinal ölçekte modellediği için bu tür düzeltmelere ihtiyaç duymaz.

8. Kapsamlı Hata Analizi ve Artık (Residual) Diagnostiği

Modelin başarısız olduğu noktaların post-hoc analizi, operasyonel güvenilirliğin anahtarıdır.

- **Zirve Talep ve Asimetrik Kayıp Fonksiyonları:** Standart MSE, yüksek talep zirvelerini (peak hours) "sıkıştırma" eğilimindedir. Operasyonel darboğazları (supply shortages) önlemek için, eksik tahmini (underprediction) aşırı tahmine göre daha ağır cezalandıran **Asimetrik Kayıp Fonksiyonları** kullanılmalıdır.
- **Anomali Stratejisi:** Festival veya grev gibi durumlardan kaynaklanan aykırı değerler silinmemelidir. Bunun yerine, bu durumlar is_event gibi gösterge (indicator) değişkenlerle yapısal olarak modele tanıtılmalıdır.

Mimari Uygulama Rehberi (Checklist)

1. **Ön İşleme:** Windspeed ve Atemp değerlerini regresyonla kalibre edin.
2. **Mühendislik:** Hafta içi/sonu rejimlerini ayıran rush_hour ve Humidex özelliklerini oluşturun; zamanı dairesel spline'larla kodlayın.
3. **Doğrulama:** TimeSeriesSplit kullanın ve mutlaka gap=48 parametresini uygulayın.
4. **Modelleme:** 'Casual' ve 'Registered' taleplerini ayrı tahmin eden dual-target mimarisini kurun; XGBoost ve TFT modellerini harmanlayın.
5. **Düzeltilme:** $\$c=100\$$ shift parametresini test edin ve Duan'ın Yayma Tahmincisi ile retransformasyon yanlılığını giderin.
6. **Analiz:** Rezidü grafiklerinde heteroscedasticity kontrolü yapın ve zirve saatler için özel düzeltme faktörleri uygulayın.